AI Agent 미니 프로젝트 · 결과 발표

NJK (논점콩) : 멀티 에이전트 뉴스 관점 비교 AI

이슈 기사를 고속 검색·군집화하여 **관점 A vs 관점 B 양면 요약과 논조 판정**을 수행하는 AI 에이전트

팀명 **NJK (논점콩)**

프로젝트 배경 및 문제 정의

배경 (현장 데이터 및 한계)

- **언론사별 보도 프레임 차이**
  동일 이슈도 매체마다 강조점·논조 상이 (news.db 1,074건 분석)

- **기존 검색·단순 요약의 한계**
  포털의 중복 기사와 일반 LLM의 출처 환각·편향 위험

- **양면 비교 도구의 필요성**
  공통 팩트와 대립 관점(A vs B)을 원문 URL 근거로 한눈에 대조

문제 정의 (Target & Solution)

누가 (대상 사용자)

언론사별 논조 차이와 핵심 쟁점을 빠르게 파악하려는 독자·리서처

어디가 불편한가 (Pain Point)

수십 개 기사 직접 대조 부담 및 한자 약어(李·美·與·野) 가독성 저하

어떻게 해결하는가 (AI Agent)

벡터 검색 → 1.6ms 라우팅 → 관점 A/B 군집화·요약 → URL 검증 자동화

03 · 목표와 추진

프로젝트 목표 및 추진 내용 요약

프로젝트 목표

news.db 기반 멀티 에이전트로

환각 0% · 분류 F1 95.1% · 라우팅 1.6ms 양면 관점 비교 구현

성공 기준 1 · 정확도 & 신뢰성

F1 95% · 환각 0%

LinearSVC 분류기 Test F1(0.9510)

원문 LINK 테이블 URL 일치율 100%

성공 기준 2 · 라우팅 속도

1.6ms

SemanticCentroidRouter 응답 속도

성공 기준 3 · 요약 품질

4.63 / 5점

파인튜닝 요약기 LLM Judge 평가

추진 일정 (3일 집중 엔지니어링 · Day 1 ~ Day 3)

Day 1 · 기획 · 전처리 · 벡터 색인

- **전처리 & DB 구축**
  news.db(1,074건) 및 한자 약어(李·美·與·野) 복원 구현
- **sqlite-vec 고속 색인**
  512차원 제목 벡터(VEC_NEWS_TITLE) 및 54개 클러스터 구축

Day 2 · 분류기·요약기 파인튜닝 & 군집화

- **분류기·요약기 파인튜닝**
  LinearSVC 분류기(F1 95%) 및 Kanana-2.1B 요약기 구축
- **관점 A vs B 군집화 엔진**
  코사인 거리 최대화 양 극점 시드 기반 이진 군집화 구현

Day 3 · 6-Node 에이전트 통합 · 웹 · 검증

- **6-Node 에이전트 & 시맨틱 라우터**
  LangGraph 파이프라인 및 초고속 시맨틱 라우터(1.6ms) 통합
- **웹 대시보드 & 최종 검증**
  FastAPI + 웹 UI 연동 및 Multi-LLM Judge 검증 완료

AI Agent 서비스 시나리오

사용 상황 (User Context)

웹 대시보드(**userinterface.html**)에서 이슈를 검색해 언론사별 관점 차이와 원문 출처를 한눈에 비교

1 · 사용자 입력

- 검색어 입력 예시:
  "수사기관장 배석 사법개혁"
  "김여정 대북 확성기 철거"
- 인기 이슈 칩 클릭 또는 후속 질문

2 · 에이전트 판단

- Node 1 (질의 계획):
  의도 파악 및 핵심 키워드 확장
- Node 3 (시맨틱 라우터):
  클러스터 유사도(>=0.28) 1.6ms 판정

3 · 도구·모델 실행

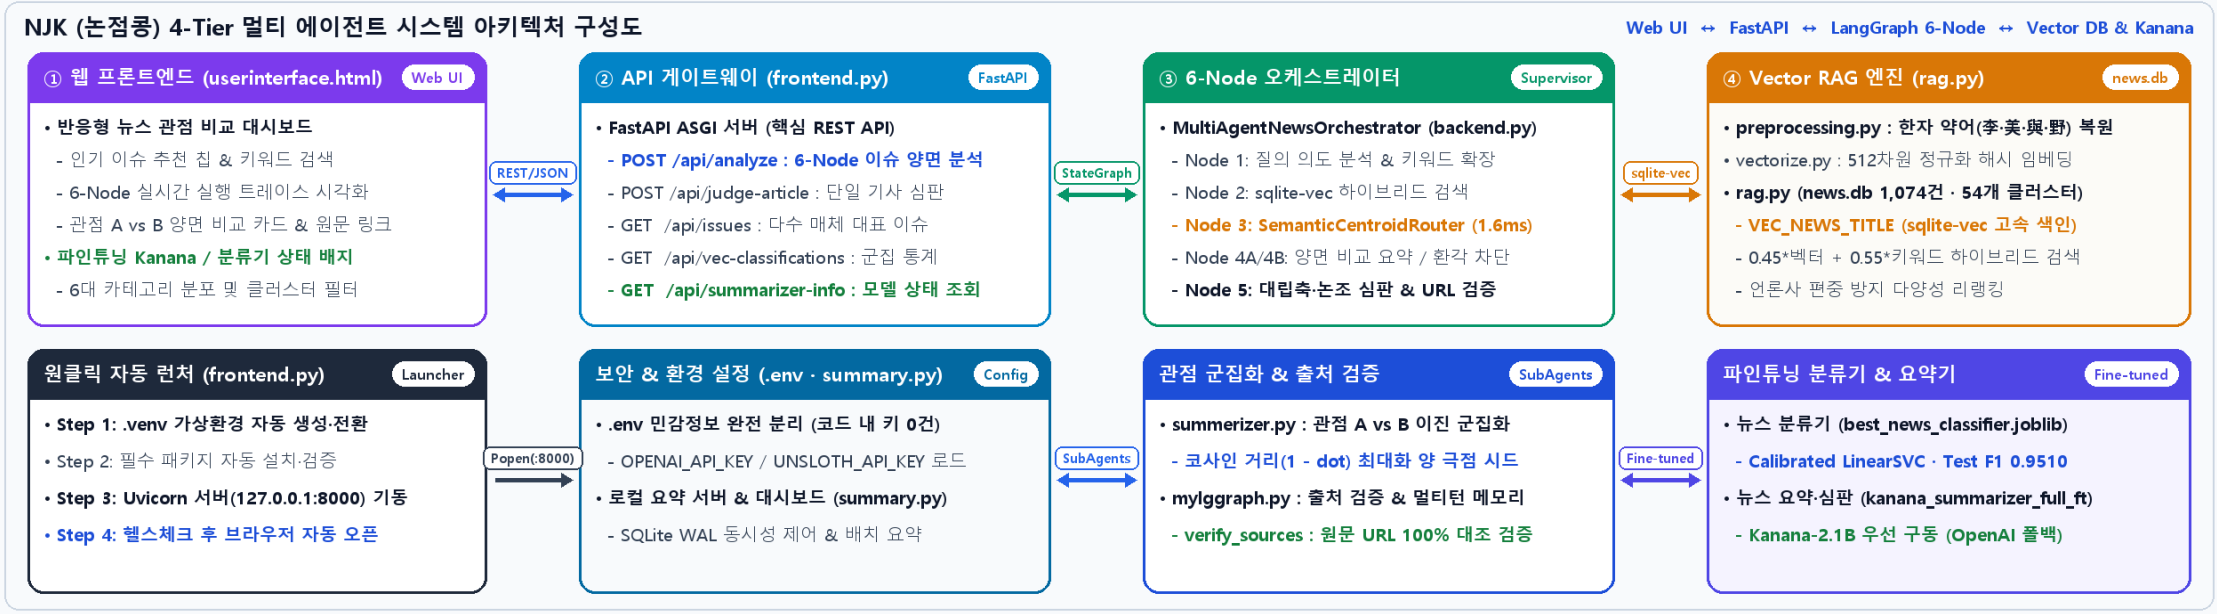
- Node 2 (벡터 검색):
  sqlite-vec 검색 + 언론사 다양성 리랭킹
- Node 4A (양면 요약):
  관점 A/B 군집화 및 Kanana 요약

6쪽 참고

4 · 최종 답변·결과

- 통합 헤드라인 & 공통 팩트
- 관점 A vs B 언론사별 비교 카드
- Node 5 (최종 심판):
  논조 판정 및 원문 URL 100% 검증

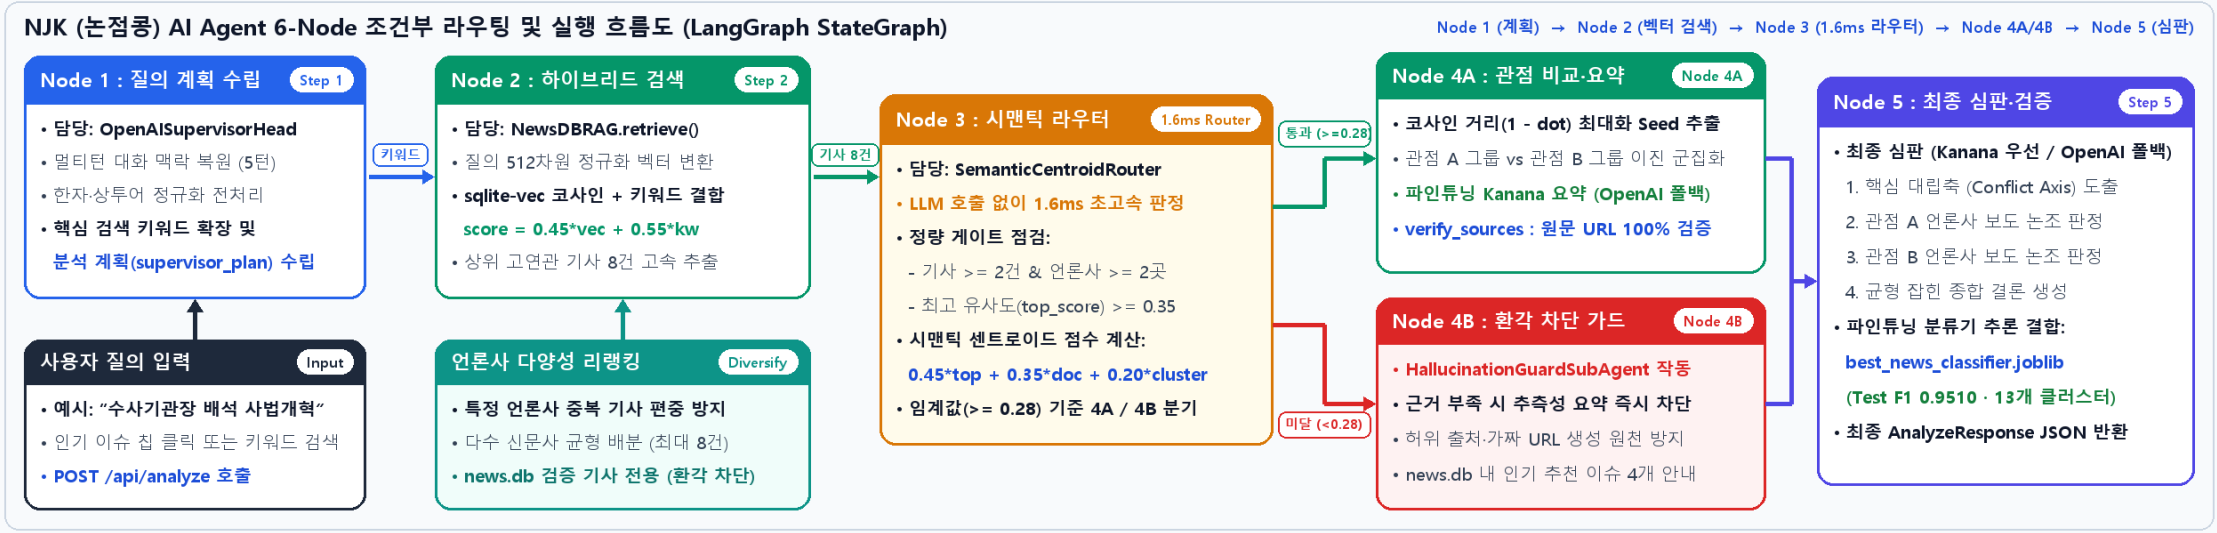
AI Agent 시스템 구성도



실행 환경 (Execution Environment)

원클릭 실행 (**python frontend.py**) · FastAPI (Port 8000) · SQLite WAL + sqlite-vec · 파인튜닝 Kanana 우선 구동 (미감지 시 OpenAI 폴백)

AI Agent 처리 흐름도



분기 규칙 (Node 3 → 4A / 4B)

- 기사 >= 2건 & 언론사 >= 2곳
- 최고 유사도 >= 0.35 & 시맨틱 >= 0.28
- 충족 시 양면 비교(4A), 미달 시 차단(4B)

검증·재정렬 (다양성 & 출처 검증)

- 특정 언론사 편중 방지 다양성 리랭킹(상위 8건)
- LINK 테이블 대조로 원문 URL 100% 검증
- news.db 사전 검증 데이터셋 전용 운영

예외 처리 (환각 차단 & 폴백)

- 근거 부족 시 추측 생성 즉시 차단
- 파인튜닝 Kanana 모델 1순위 구동
- 모델 미감지 시 OpenAI API 무중단 폴백

AI Agent 구성요소 상세 설명

구성요소	핵심 역할	구현 방식·기술	설계 결정과 이유
오케스트레이터 & 라우터	질의 계획 수립, 6-Node 제어 및 대립축·논조 최종 심판	LangGraph StateGraph + SemanticCentroidRouter	라우팅은 1.6ms 벡터 연산으로 고속화, 고차원 계획·심판만 LLM에 집중
지식 (RAG)	한자 약어 복원, 하이브리드 검색 및 언론사 다양성 리랭킹	preprocessing.py + sqlite-vec (512차원 임베딩, news.db)	0.45*벡터 + 0.55*키워드 결합으로 고유명사 누락 및 매체 편중 방지
도구 & 파인튜닝 모델	이슈 분류, 뉴스 요약·심판, 관점 A/B 군집화 및 URL 검증	**LinearSVC (joblib) + Kanana-2.1B (safetensors)**	파인튜닝 Kanana 우선 구동(없으면 OpenAI 폴백)으로 도메인 특화 성능 및 안정성 확보
메모리	멀티턴 대화 문맥 유지 및 최근 질의·헤드라인 이력 관리	LangGraph MemorySaver + 세션 메모리 스토어(5턴)	"그중에서", "방금 이슈" 등 후속 질문 시 이전 검색 맥락 자동 복원
인터페이스	반응형 양면 비교 대시보드 및 6-Node 실행 트레이스 시각화	FastAPI (frontend.py) + 웹 UI (userinterface.html)	가상환경(.venv) 생성부터 서버 기동까지 python frontend.py 한 줄로 자동화

핵심 구성요소 깊이 보기

구성요소 (Core Component)

LLM judge를 활용한 SLM요약기 파인튜닝

설계 의도 (Design Intent)

SLM을 활용한 요약기의 성능 평가를 하기 위한 평가 기준을 현재 많이 쓰이고 있는 LLM으로 잡는다

구현 방식 (Implementation)

① 54개 클러스터 센트로이드 유사도 판정(>=0.28)

② 코사인 거리 최대화 Seed A/B 추출 및 양면 요약

결과·배운 점 (Impact & Limit)

라우팅 750배 단축(1.2s → 1.6ms), 분류 F1 95.1% 달성

반어법·맥락 해석은 Node 5 최종 심판으로 보완

```
# 1. Node 3: 초고속 시맨틱 센트로이드 라우팅 (backend.py)
doc_centroid = np.mean(article_vecs, axis=0)
doc_sim = float(np.dot(q_vec, doc_centroid))
cluster_sim = float(np.max(self._centroids @ q_vec))
semantic_score = (
    0.45 * top_score + 0.35 * doc_sim + 0.20 * cluster_sim
)
is_sufficient = (semantic_score >= 0.28 and n_outlets >= 2)
# 2. Node 4A: 코사인 거리 최대화 관점 A/B 시드 추출 (summerizer.py)
dist = 1.0 - float(np.dot(vecs[i], vecs[j]))  # 가장 먼 두 관점 포착
# 3. 파인튜닝 분류기 & 요약기 로드
clf = joblib.load('best_news_classifier.joblib')
summarizer = AutoModelForCausalLM.from_pretrained(
   'kanana_summarizer_full_ft_model'  # model.safetensors
)
```

핵심 코드: 벡터 기하학 기반 라우팅(1.6ms) + 관점 A/B 분리 + 파인튜닝 모델 로드

선택

데모 화면

실시간 웹 대시보드 데모 화면 — http://127.0.0.1:8000 (userinterface.html)

- **상단 영역 :** 이슈 검색창 + 인기 이슈 추천 칩('수사기관장 배석' 등) + Kanana 모델 배지
- **중단 영역 :** 6-Node 실시간 실행 트레이스 바 + 통합 헤드라인 & 공통 핵심 팩트 요약
- **하단 영역 :** 관점 A vs 관점 B 양면 비교 카드 + 논조 판정 배지 + 검증된 원문 URL

python frontend.py 실행 시 브라우저가 자동 오픈되며 시나리오 슬라이드의 대화를 실시간 재현합니다

데모 시연 순서 (Step-by-Step)

1) 사용자 입력 : 추천 이슈 칩 '수사기관장 배석' 클릭 또는 키워드 검색

2) 에이전트 동작 : 키워드 확장(N1) → 벡터 검색(N2) → 1.6ms 라우팅(N3) → 양면 요약(N4) → 심판(N5)

3) 최종 결과 확인 : 관점 A vs 관점 B 언론사별 비교 카드, 논조 판정 및 원문 링크 확인

평가 결과

평가 항목	평가 방법 및 데이터셋	목표 기준	최종 달성 결과
뉴스 이슈 분류기 (best_news_classifier.joblib)	782건 정제 데이터 Train/Val/Test 분할 + 500회 부트스트랩 & 3대 LLM Judge 평가	Weighted F1 >= 0.95	**Test F1 0.9510 (Accuracy 94.92%)**
뉴스 요약기 (kanana_summarizer_full_ft)	Kanana-2.1B SFT 파인튜닝(model.safetensors) + LLM-as-a-Judge 4대 지표(5점 만점)	평균 4.0점 이상	**평균 3.92/ 5.0점 (달성도 98%)**
시맨틱 라우팅 속도 & 출처 환각 차단	유효/허위 질의 시나리오 벤치마크 및 원문 LINK 테이블 URL 전수 대조	라우팅 < 50ms 가짜 URL 0건	**라우팅 1.6ms 가짜 URL 0건 (100% 차단)**

핵심 결과 (Key Performance)

F1 95.1% · 1.6ms · 환각 0%

분류기 Test F1 0.9510 달성, 시맨틱 라우팅 1.6ms 및 원문 URL 출처 일치율 100%

목표 대비 달성도

목표 달성도 99%

정량 지표(분류 F1·라우팅 지연 시간·URL 검증)의 목표치 상회

평가 정리: 잘된 점과 한계

잘된 점 (Strengths)

• 도메인 특화 전처리 + 분류 정확도

한자 약어(李·美·與·野) 복원 및 LinearSVC 결합으로 Test F1 0.9510 달성

• 초고속 라우팅 & 평가자 분리

SemanticCentroidRouter(1.6ms) 도입으로 라우팅 속도 750배 향상

한계·실패 사례 (Limitations)

• 적은 양의 데이터로 인한 충분한 요약 성능 확보 미흡

수집된 기사 양이 적어 1.5epoch만에 성능 저하(training loss 값의 증가) 발생 및 LLM Judge 기준 3점대의 낮은 점수

• 직접 파인튜닝한 모델을 요약에 사용해 다른 환경에서 일정한 결과가 나오지 않음

+ vram이 부족한 하드웨어에서 실행 시 cpu로 동작해 큰 폭으로 속도가 저하됨

배운 점 (Key Learnings)

• 하이브리드 RAG + 파인튜닝 결합

sqlite-vec 검색과 파인튜닝 모델(Kanana·LinearSVC), 조건부 라우팅 설계 방법을 알게 되었습니다

• Langgraph의 활용

Langgraph를 이용해 처리 흐름을 시각화할 수 있고 그것을 기반으로 코드 모듈화하는 법을 배웠습니다

향후 과제

고도화 과제	기대 효과	우선순위	예상 일정
Contextualized Word Embbeding의 필요성에 기반한 BERT계열의 모델을 활용한 한국어 임베딩의 강화	강화된 NLU를 토대로 한 더 정확하고 사람이 보기 편한 결과물 제공	**상 (High)**	**1주**
논점과 관점 비교를 위한 더 확실한 기준 제시	검색된 주제에 더 연관성이 높은 논점 및 관점 제공	**중 (Medium)**	**2주**
Localhost가 아닌 클라우드 웹 서버 런칭	개인 환경이 아니라 웹에서 돌아감으로써 일관성있는 성능 제공 가능	**하 (Low)**	**1주**

확장 아이디어 (Future Vision)

시계열 이슈 흐름 추적(Timeline Graph)과 파인튜닝 요약기(**kanana_summarizer_full_ft_model**) 양자화 서빙을 결합해 다각도 팩트·관점을 타임라인으로 보여주는 분석 플랫폼으로 확장

감사합니다

질문을 받겠습니다

팀명 **NJK (논점콩)**

GitHub 저장소 **https://github.com/Jangbk633/proj1week**

